实验2：基于MapReduce的用户信贷数据分析

背景

每个银行都有大量的信用贷款客户，随着近年来银行面向个人的小额贷款业务的不断发展，防范个人信贷欺诈，降低贷款不良率，提高银行回款率是银行开展相关业务的首要目标。银行积累了海量脱敏客户业务数据集，数据不仅包含客户基础信息，还涵盖开户机构、资产负债水平、财富规模、各类理财渠道交易行为、个贷逾期标记bad_good等丰富特征。客户的资产规模、负债水平、所在机构客户结构、理财行为习惯，都有可能是影响客户信贷逾期风险的重要潜在特征。

本实验基于 Hadoop MapReduce 分布式计算框架完成数据分析与建模预测流程。任务1~4对原始银行客户数据做特征工程层面的预处理与统计探索分析，挖掘客户资产分布、分群特征，为信贷用户逾期预测任务提供统计基础与特征支撑；任务 5 在前期数据分析基础上，利用 MapReduce 框架实现客户信贷风险预测模型，理解分布式计算框架下机器学习预测任务的实现思路。本次实验目的是为了掌握 MapReduce 编程范式，重点学习分布式缓存、Mapper/Reducer 分工、任务调度、模型加载与分布式预测等 MapReduce 核心知识，模型预测的分数高低不是重点。

数据来源：用户逾期行为预测 竞赛 - DataFountain

数据描述

原数据集中含有627个字段，经过筛选，只剩下15个对本次实验有用的字段。其中数据集分为train.csv以及test.csv，任务1~4属于数据分析任务只会使用到train.csv，任务5则是预测任务会用到train.csv和test.csv。

客户信息表（customer_info）

包含约28万用户的各个信息，主要包括客户号、开户机构、个贷是否逾期、资产总额、负债总额等字段。

列名	类型	含义	示例
CUST_ID	bigint	客户唯一标识ID	1000086234
OPEN_ORG_NUM	bigint	开户机构编号	51010034
bad_good	bigint	客户好坏标签	0 / 1
CUST_SAVING_AMT	double	存款金额	1256
CUST_FINA_AMT	double	理财金额	250000.00
CUST_PRIFINA_AMT	double	私人银行理财金额	86200.50
CUST_FOND_AMT	double	基金金额	152000.00
CUST_NADEBT_AMT	double	国债金额	210000.00
CUST_YBT_AMT	double	银保通金额	58000.00
CUST_METAL_AMT	double	贵金属金额	32000.00
CUST_ASSET_AMT	double	资产总额	18600.00
CUST_DEBT_AMT	double	负债总额	45200.00
G_OS_PRCP_SUM	double	贷款账户月余额	204750.0
LOAN_FLAG	string	个贷标识	Y
CRED_FLAG	string	持有基金标志	Y

实验任务

任务1：各开户机构客户数量以及资产统计

根据`train`表中的数据，编写MapReduce，统计各个开户机构的客户数量、该机构所有客户的总资产和总负债、个贷逾期客户数。

注： 每个客户的资产总额和负债总额分别由字段`CUST_ASSET_AMT`和`CUST_DEBT_AMT`表示。请注意处理数据中的缺失值，将其视为零即可。

输出格式：

```
<开户机构编号>TAB<客户数量>,<总资产>,<总负债>，<个贷逾期客户数>
```

示例：

```
1001    1254,184485852.19,112193577.37,18
```

任务2：平均值分析

根据任务一的结果，编写MapReduce程序，统计各机构中客户资产高于以及低于个机构的客户资产平均值的客户数量。

注：如客户资产等于平均值，则归入大于部分；

输出格式：

```
<开户机构编号>TAB<高于平均值客户数量>,<低于平均值客户数量>
```

示例：

```
1001    232,1022
```

任务3：找出客户总资产的四分位数

依据资产总额找出四分位数：对客户资产总额开展分位数分析，任务采用 Java MapReduce 编程实现，MapReduce 的排序是框架内置的自动机制，不是我们自己写代码调用 sort，整个流程为 Map → Shuffle (分区、排序) → Reduce。获得全局有序的资产序列后，结合总样本条数计算得到 25%、50%、75% 四分位数

输出格式：

```
Q25:<25分位数> TAB Q50:<中位数> TAB Q75:<75分位数>
```

任务4：客户资产分层与资产结构统计

基于任务三计算得到的客户资产总额四分位数划分客户资产等级，将全部客户划分为低资产、中等资产、较高资产、高资产四个层级；分别统计各层级下客户的存款、理财、私人理财、基金、国债、银保通、贵金属各类资产的汇总规模，计算每一类资产在对应资产等级内的占比，以此对比不同资产层级客户的资产配置结构差异，挖掘不同客户群体的资产配置偏好，为客户分层营销、产品运营提供数据支撑。最终输出先按照等级排序，接着按照占比大小（由大到小）排序。

```
输出格式:
<等级>TAB<资产种类>TAB<占比>
```

示例：

```
中等资产	存款	0.9858
```

任务5：基于 MapReduce 实现客户风险预测

在前面任务的数据探索、资产分层特征工程基础上，基于 MapReduce 分布式框架完成客户信贷逾期风险预测任务。

实验核心目标：学习 MapReduce 分布式编程模型，掌握分布式缓存、Mapper/Reducer 分工、任务提交、资源配置等 Hadoop MapReduce 开发技能，**不限制使用的机器学习模型**（可选用朴素贝叶斯、K 近邻 KNN 等分类算法），模型预测效果不做硬性最优要求。

数据集使用：训练集`train.csv`包含客户特征与标签`bad_good`，用于模型训练 / 构建；测试集`test.csv`仅包含客户特征，无标签`bad_good`，作为 MapReduce 任务输入，完成逾期标签预测。

```
输出格式:
<CUST_ID>TAB<预测bad_good>
```

提交方式

提交git仓库地址或者相关文件的zip包。实验报告应包括设计思路、运行结果和可能的改进之处等。git仓库目录组织建议：

```
.(Project Name)
├── src
├── target   (只保留jar文件，忽略其它无关文件)
├── output
│   └── task1/ (输出结果)
|   └── task2/
|   └── ...
├── pom.xml (按需)
├── .gitignore
└── README.md (对设计思路，程序运行结果等给出说明，并给出提交作业运行成功的WEB页面截图。可以进一步对性能、扩展性等方面存在的不足和可能的改进之处进行分析。)
```